

# Algorytmy metaheurystyczne 3

Paweł Cegieła, Wojciech Sęk

26 maja 2022

## 1 Rodzaje algorytmu

Algorytm genetyczny można podzielić ze względu na dwie znaczące modyfikacje:

- algorytm może działać na jednej populacji lub na wielu populacjach żyjących na osobnych wyspach
- algorytm może działać całkowicie sekwencyjnie lub wykonywać część obliczeń równolegle

## 2 Parametry algorytmów

Dla algorytmu sekwencyjnego z jedną populacją podajemy następujące parametry:

- *matrix*: macierz przechowująca odległości między miastami z problemu TSP
- *gen\_rand*: wartość logiczna mówiąca, czy pierwsze pokolenie ma być całkowicie losowe czy przybliżone innymi metaheurystykami
- *gen\_size*: licznosc populacji na każdym etapie algorytmu
- *elite\_num*: licznosc elity, czyli najlepszych rozwiązań, które przeżywają i przechodzą do następnego pokolenia
- *cross\_op*: wartość enumeratywna mówiąca o tym, jaki typ krzyżowania zostanie użyty w algorytmie. Możliwe wartości:
  - 0 - HALF CROSSOVER: dziecko w każdym kroku generowania przyjmuje kolejne od jednego z rodziców miasto z prawdopodobieństwem 1/2, bierzemy najwcześniejsze miasto z rodzica, które nie występuje w dziecku
  - 1 - ORDER CROSSOVER: pół dziecka to podciąg rodzica, drugie pół to podciąg drugiego rodzica składający się z nieużytych wcześniej miast i zaczynający od miasta występującego na tym miejscu w pierwszym rodzicu
  - 2 - CYCLE CROSSOVER: bierzemy miasto z pierwszego rodzica, patrzymy na miasto pod danym indeksem w drugim rodzicu, idziemy do niego w pierwszym rodzicu, powtarzamy aż zamknijemy cykl. Resztę uzupełniamy drugim rodzicem.
  - 3 - PARTIALLY MAPPED CROSSOVER: na danym podciągu indeksów tworzymy mapę między rodzicami, następnie używamy pociągu z jednego rodzica i zmapowanych wartości z drugiego.
- *swap\_change*: wartość logiczna decydująca o tym, czy w trakcie mutacji poruszamy się w sąsiedztwie *swap* czy *reverse*
- *size\_of\_tournament*: rozmiar turnieju przy losowaniu rodziców do tworzenia nowego pokolenia. Wartość ustawiona na 0 sprawia, że zamiast turnieju korzystamy z zasady ruletki, gdzie funkcja dopasowania jest odwrotnością wagi danej permutacji.
- *mut\_chance*: prawdopodobieństwo, że dany osobnik zmutuje.
- *max\_time*: ograniczenie czasowe, po którym algorytm kończy działanie. Wynik zwracany przez algorytm to najlepszy wynik znaleziony przed przekroczeniem limitu czasowego.

Dla algorytmu wyspowego podajemy także:

- *isles\_num*: liczba wysp
- *migration\_freq*: liczba iteracji, które dzielą od siebie moment wymiany genetycznej między wyspami

W algorytmach urównoleglonych podaje się również parametr *num\_of\_threads*, który mówi o liczbie wątków.

### 3 Teoretyczna złożoność

Rozważmy złożoności poszczególnych etapów w algorytmie sekwencyjnym bez wyp. Niech  $n$  to liczba miast, a  $k$  to liczność pokolenia:

- **Wyznaczanie populacji początkowej:** w języku Rust losowanie permutacji ma złożoność  $O(1)$ , zatem losowa generacja osobników ma złożoność  $O(k)$ . Dla przybliżeń przez inne metaheurystyki co najwyżej  $\frac{k}{4}$  jest przybliżone, w naszym przypadku dajemy jeden raz  $2 - OPT$  ze złożonością  $O(n^3)$  i pozostałe to *nearest – neighbours* od losowego miasta ze złożonością  $O(n^2)$ .
- **Ewaluacja:** Obliczanie wartości danej permutacji ma złożoność  $O(n)$ , robimy to  $k$  razy, zatem cały krok ma  $O(kn)$ .
- **Selekcja:** Wybieramy  $k$  rodziców. Przy ruletce wybór rodzica ma złożoność  $O(1)$ , przy turnieju  $O(l)$ , gdzie  $l$  to rozmiar turnieju. Zatem  $O(k)$  dla ruletki i  $O(kl)$  dla turnieju.
- **Krzyżowanie:** Każde z krzyżowań odbywa się w czasie liniowym względem długości permutacji, czyli  $O(n)$ , przy tworzeniu całej permutacji mamy  $O(kn)$ .
- **Mutacja:** mutacja typu *swap* ma złożoność  $\Theta(1)$ , a typu *reverse*  $\Theta(n)$ . Mutacji wykonujemy  $\Theta(pn)$ , gdzie  $p$  to prawdopodobieństwo mutacji. Zatem ta faza ma złożoność  $\Theta(pn)$  lub  $\Theta(pn^2)$ . W worst case możemy wylosować wszystkie, więc odpowiednio złożoności są  $O(n)$  i  $O(n^2)$ .

Ponadto w algorytmie wyspowym regularnie w niektórych iteracjach wymieniana jest informacja genetyczna ze złożonością  $O(k^2)$  (każda wyspa wymienia się z każdą jakimś osobnikiem).

Podsumowując, w najgorszym przypadku:

- **Generacja początkowej populacji:**

$$O(n^3 + kn^2 + k) = O((n + k)n^2)$$



- **Właściwa iteracja:**

$$O(kn) + O(kl) + O(kn) + O(n^2) + O(k^2) = O(k(n + l + k) + n^2)$$

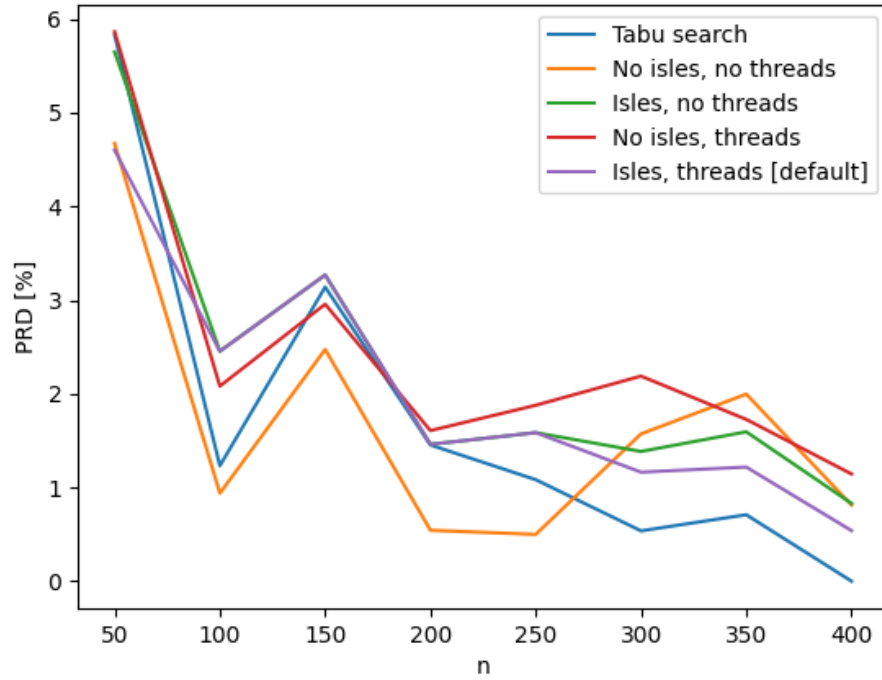
### 4 Wykonane eksperymenty

Strojenie algorytmu zostało wykonane na podstawie danych z TSPLIB. Wybrane zostały parametry, dla których algorytm najlepiej zachowywał się podczas testowania. Jeśli jeden z dwóch parametrów miał np. lepsze wyniki od drugiego dla jednych danych (np. dla mniejszych wielkości macierzy), a gorsze dla innych, wybierany był jeden z tych parametrów po przemyśleniu. Po strojeniu zostały przeprowadzone eksperymenty porównujące algorytm w wersji oraz z parametrami wybranymi jako domyślne: z innymi wersjami algorytmu oraz z tabu search, a także z różnymi wartościami parametrów. Nie w każdym eksperymencie czy nie dla każdego typu macierzy domyślny algorytm okazał się najlepszy, natomiast strojenie pomogło nam znaleźć taki algorytm oraz parametry, które średnio zachowują się najlepiej.


#### 4.1 Porównanie wersji algorytmu genetycznego i tabu search

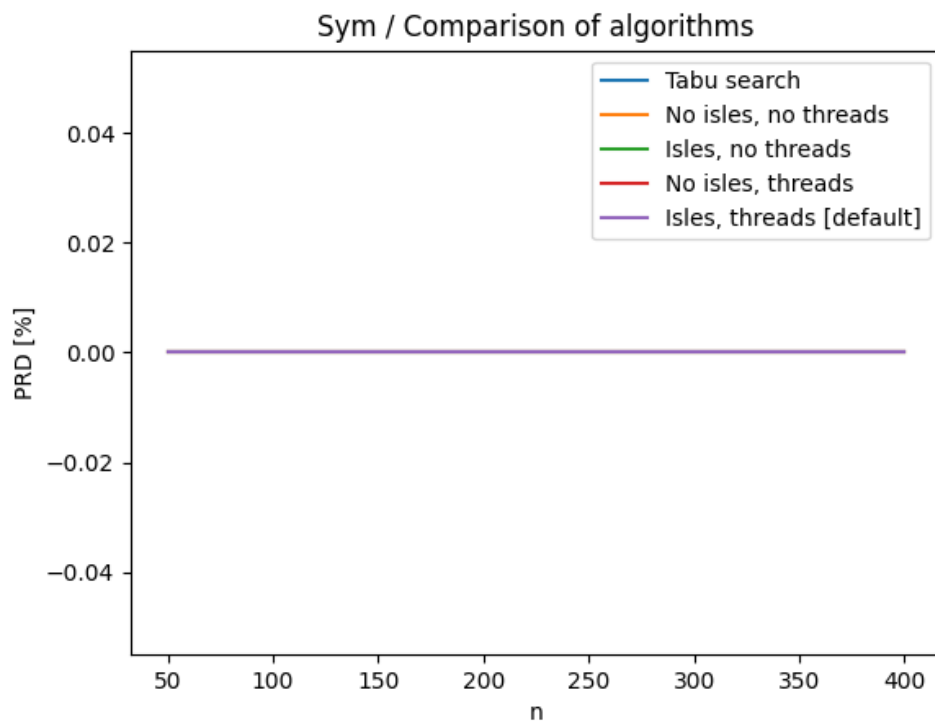


Asym / Comparison of algorithms






Euclid / Comparison of algorithms









## 4.2 Przybliżenie początkowe










### 4.3 Wielkość pokolenia




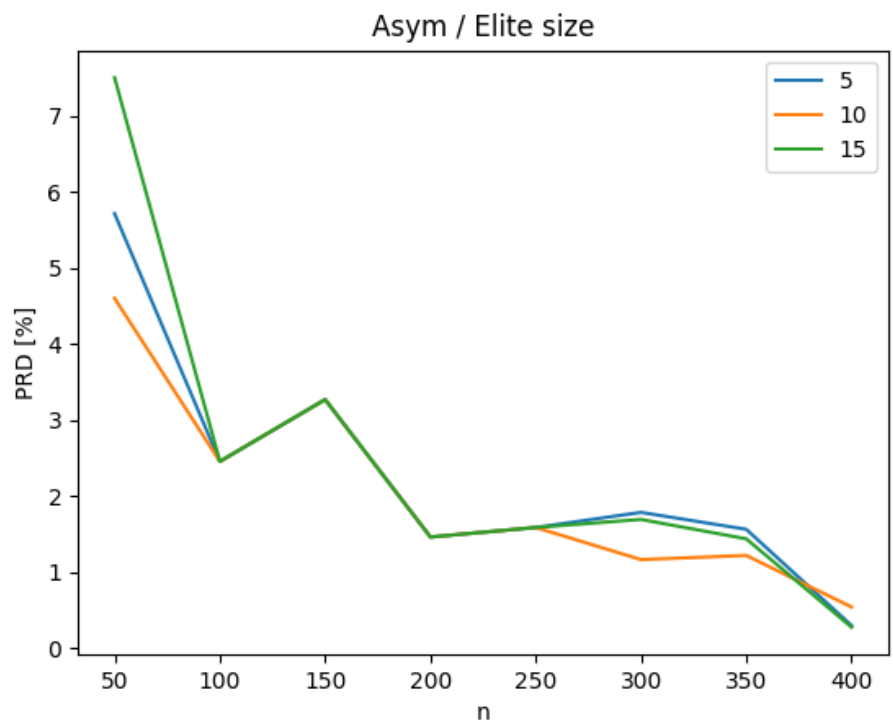



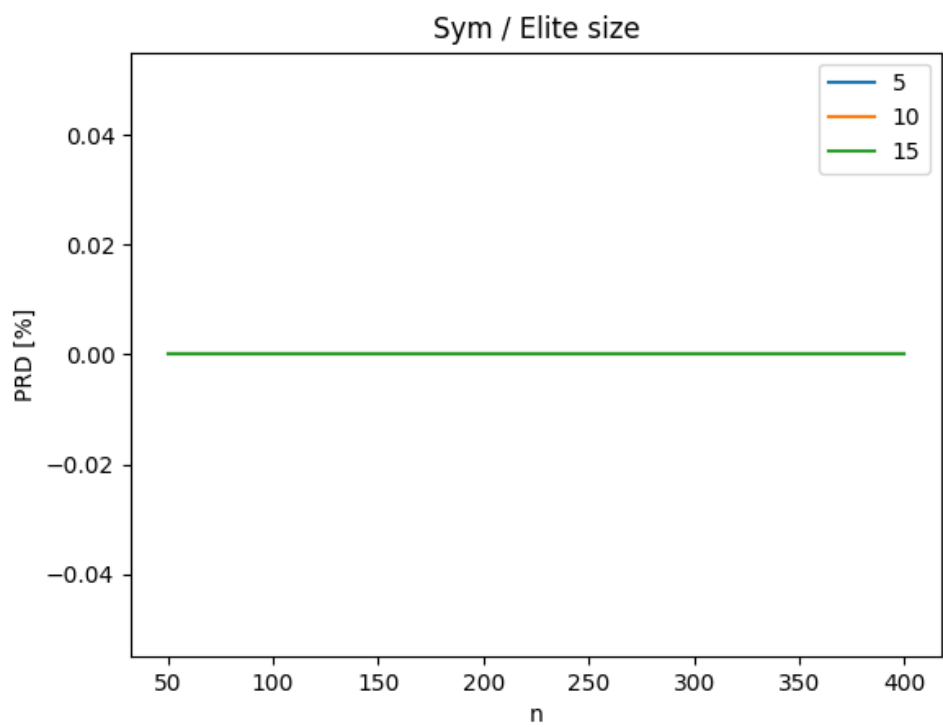
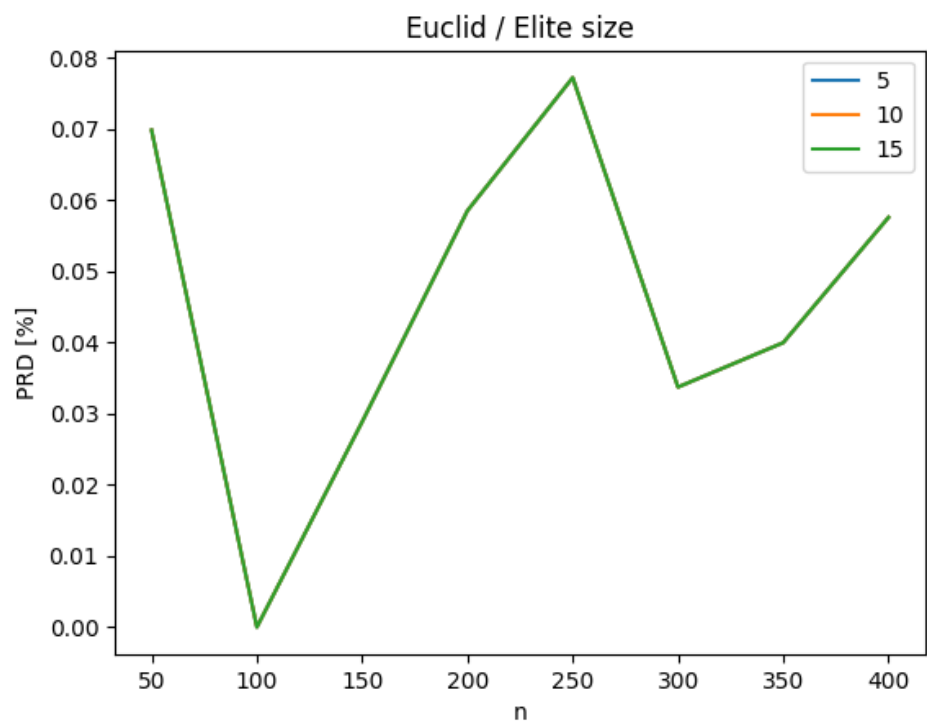






#### 4.4 Wielkość elity









4.5 Krzyżowanie




Asym / Crossing methods




Euclid / Crossing methods







#### 4.6 Swap i inverse




TSPLIB\_euclid / Swap and inverse in mutation



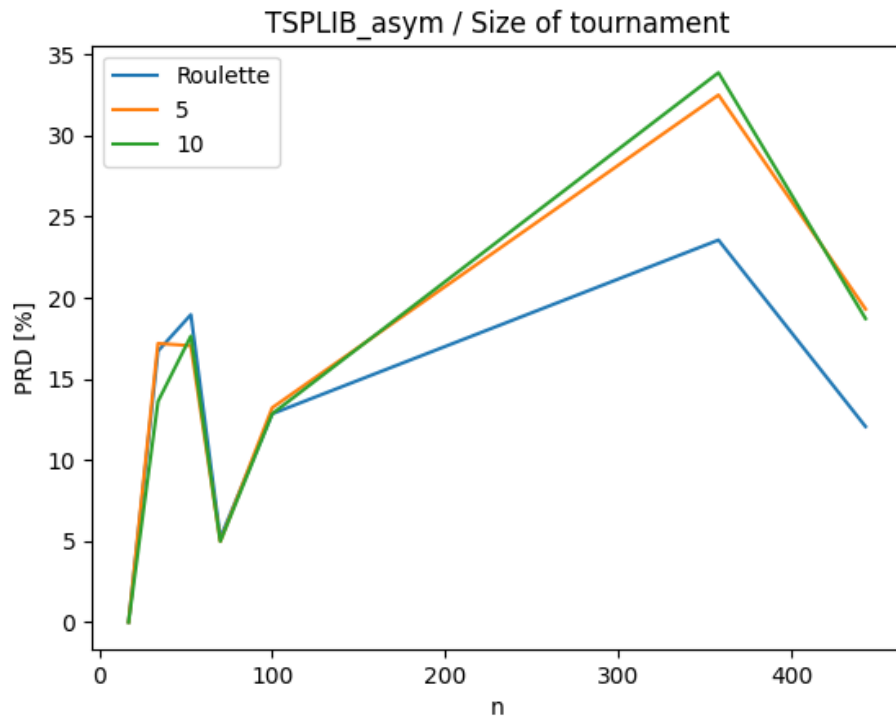
Asym / Swap and inverse in mutation









## 4.7 Turniej




Asym / Size of tournament






Euclid / Size of tournament









#### 4.8 Szansa mutacji










## 4.9 Maksymalny czas
















#### 4.10 Liczba wysp











#### 4.11 Częstotliwość migracji











#### 4.12 Liczba wątków







## 5 Obserwacje i wnioski

- W przypadku praktycznie wszystkich testowanych macierzy, algorytm genetyczny działał tak samo dobrze lub gorzej od zaimplementowanego na liście 2 przeszukiwania tabu. Pozwala to stwierdzić, że dla problemu komiwojażera najbardziej opłaca się użyć tabu search (jeśli chcemy otrzymać najlepsze wyniki) lub 2-opta (jeśli zależy nam na czasie, ale wyniki wciąż mają być stosunkowo dobre).
- Dla każdego typu macierzy powtórzył się jeden wynik - jeśli pierwsze pokolenie było całkowicie losowe, to dawało to bardzo słabe rezultaty, nawet nie zbliżające się do optymalnych. Natomiast przy przybliżeniu pierwszego pokolenia innymi



metaheurystykami(2-OPT) wyniki stawały się bardzo dobre.

- W przypadku macierzy symetrycznych, podobnie jak w eksperymentach z poprzedniej listy, nie ma różnicy w wynikach w zależności od wybranych parametrów. Dla tych macierzy optymalnym rozwiązaniem jest 2-opt, ponieważ algorytmy startujące z przybliżenia początkowego generowanego przez 2-opt nie poprawiają wyników.
- Dla macierzy euklidesowych różnice między poszczególnymi algorytmami i wybranymi parametrami istnieją, ale są minimalne.
- Macierze asymetryczne dostarczają znacznie bardziej różnorodnych wyników:

Najlepszy okazał się algorytm z wątkami i wyspami, chociaż dla mniejszych macierzy generowanych przez nas najlepszy okazał się algorytm bez wątków oraz wysp, pokonując nawet tabu search.

Najlepszy rozmiar macierzy dla danych z TSPLIB to 100, osiągając podobny wynik do 50, natomiast największy testowany rozmiar - 150 - miał znacznie gorsze wyniki. Dla danych generowanych wyniki były bardziej do siebie zbliżone i ciężko jednoznacznie określić zwycięzcę.

Algorytm dawał najlepsze wyniki dla większych wielkości elity (10 i 15 na 100-osobowe pokolenie), niż mniejszej (5).

Średnio najlepszą metodą krzyżowania okazała się Order Crossover.

Metoda swap stosowana przy mutacji dawała znacznie lepsze rezultaty niż inverse (często nawet dwukrotnie lepsze).

W danych z TSPLIB zdecydowanie najlepiej wypadł turniej z wykorzystaniem zasady ruletki, niż klasyczny turniej z ustalonymi wielkościami. Co ciekawe, na danych generowanych przez nas wyniki ruletki były dla wielu n najgorsze.

Zwiększanie szansy mutacji do pewnego stopnia poprawiało otrzymywane wyniki - najwyższa szansa mutacji (0.1) dawała najlepsze wyniki.

Ograniczenie czasowe nie wpływało aż tak na wyniki - o ile najkrótszy czas (5 sekund) dawał najgorsze rezultaty, to pomiędzy 10 i 15 sekund nie było aż takiej różnicy, a wyniki były nawet często lepsze dla średniego czasu (10s).

Liczba wysp dawała zawsze zbliżone wyniki dla 5, 10 i 15 wysp, często różnie dla różnych wielkości macierzy, zatem ciężko wybrać najlepszą wartość.

Optymalną częstotliwością migracji na podstawie wykresów można nazwać 10.

Optymalną liczbą wątków są 4, ponieważ w przypadku większej liczby wątków obliczenia i tak nie wykonają się równolegle, a komunikacja między wątkami kosztuje.